Documentación Técnica: Proceso KDD para Detección Automatizada de Fraude, Descubrimiento de Anomalías y Reglas de Decisión — *Credit Card Fraud Detection 2026*

Metadato	Detalle
Dataset Fuente	`credit_card_fraud_detection_2026.csv` (`100,000` registros × `43` variables)
Tecnologías	Python `3.12`, `pandas`, `numpy`, `scikit-learn`, `imbalanced-learn` (`SMOTE`), `seaborn`, `matplotlib`

1. Resumen Ejecutivo y Propósito del Proyecto

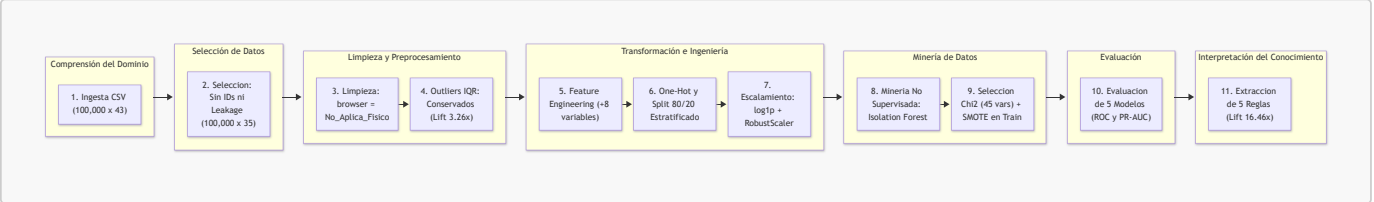
Este proyecto implementa de principio a fin las **7 etapas de la metodología KDD (*Knowledge Discovery in Databases*)** sobre el conjunto de datos transaccionales `credit_card_fraud_detection_2026.csv` (`100,000` transacciones calibradas con estadísticas de la Reserva Federal, Informe Nilson, FICO y el Banco Central Europeo).

El problema central resuelto consiste en **identificar señales débiles de fraude dentro de un conjunto de datos masivo y estadísticamente desbalanceado** (`97.945%` de operaciones legítimas frente a `2.055%` fraudulentas, razón `1 : 47.66`), articulando:

1. **Auditoría contra Fuga de Información (*Data Leakage*) y Sesgo de Selección:** Identificación de variables post-evento (`fraud_type`, `fraud_amount_lost`) y tratamiento estructural de los `41,709` valores faltantes en `browser` asociados a operaciones físicas (`POS Terminal` y `ATM`).
2. **Detección de Valores Atípicos (*Outlier Detection*):** Evaluación paramétrica/no paramétrica mediante **Criterio** $1.5 \times \mathrm{IQR}$ **de Tukey** y minería no supervisada con `IsolationForest`, demostrando que los valores atípicos concentran hasta `3.75x` más probabilidad de fraude.
3. **Ingeniería y Selección Estadística de Características:** Creación de `8` variables derivadas de dominio (incluyendo el índice multiseñal `composite_risk_index`) y filtrado mediante **Prueba Chi-Cuadrado (χ^2)** e importancia Gini.
4. **Clasificación Supervisada con Balanceo Sintético (*SMOTE*):** Comparación rigurosa de `5` algoritmos (*Dummy Baseline*, *Regresión Logística*, *Árbol de Decisión*, *Random Forest* y *Gradient Boosting*) con calibración de umbral sensible al costo (F_2-Score).
5. **Extracción de Reglas de Decisión Accionables:** Descubrimiento y validación de reglas de negocio interpretables con un *Lift* de hasta `16.46x` sobre la tasa base de fraude.

2. Arquitectura del Pipeline KDD y Modalidades de Ejecución

2.1 Arquitectura del Pipeline



2.2 Modalidades de Ejecución

Catálogo de Módulos y Entregas

1. Modalidad 1 — Entrega Unificada (../src/Entrega_Unificada/):

- Proyecto_Final_KDD_Deteccion_Fraude_2026.ipynb: Cuaderno Jupyter maestro de principio a fin.

- Proyecto_final_data_mining.py: Script completo ejecutable en un solo paso.

2. Modalidad 2 — Entrega Modular en Notebooks Separados (../src/Entrega_Modular_en_Notebooks_Separados/):

- 01_KDD_Seleccion_Limpieza_y_Outliers.ipynb
- 02_KDD_Transformacion_Ingenieria_y_Seleccion_Variables.ipynb
- 03_KDD_Mineria_IsolationForest_SMOTE_y_Modelado.ipynb
- 04_KDD_Evaluacion_Interpretacion_y_Reglas_Decision.ipynb

3. Modalidad 3 — Paquete Modular de Ingeniería de Software (../src/Entrega_Modular_de_Ingenieria_de_Software_en_Python/):

- orquestador_modular_kdd.py
- fase1_seleccion_y_limpieza.py
- fase2_transformacion_y_seleccion.py
- fase3_mineria_anomalias_y_clasificacion.py
- fase4_evaluacion_y_reglas_decision.py

4. Documentación Complementaria (../Documentacion_adicional/):

- Diccionario_Funciones_Proyecto_Final_KDD.md
- Selección de base de datos.pdf

---

3. Desarrollo Detallado por Etapas KDD

3.1 Etapa 1 y Etapa 2: Comprensión del Dominio y Selección de Datos

- Distribución de la clase objetivo (is_fraud):
  - Clase 0 (Legitimate): 97,945 registros (97.945%).
  - Clase 1 (Fraud): 2,055 registros (2.055%).
  - Pérdida financiera acumulada: $279,842.20 USD (media de $136.18 USD y máximo de $4,482.16 USD por evento fraudulento).
- Desglose por tipología de fraude (fraud_type):
  - Card-Not-Present: 1,054 casos (51.29%)
  - Account-Takeover: 447 casos (21.75%)
  - Synthetic-Identity: 309 casos (15.04%)
  - Card-Present: 245 casos (11.92%)
- Auditoría de Data Leakage: Se excluyeron fraud_type y fraud_amount_lost del conjunto predictor X porque son variables registradas post-facto con dependencia determinista sobre is_fraud. También se descartaron los identificadores transaction_id, customer_id, card_id, merchant_id, transaction_datetime y customer_state.

3.2 Etapa 3: Limpieza de Datos y Diagnóstico de Valores Atípicos (Outliers)

1. Tratamiento de valores faltantes estructurales en browser (41,709 registros, 41.71%):
   - Se demostró que los 41,709 valores NaN se distribuyen exactamente en 35,777 transacciones In-store (POS Terminal) y 5,932 transacciones ATM.
   - Eliminar filas habría borrado el 100% de la operatoria presencial del banco (Sesgo de Selección). Se imputó la categoría explícita 'No_Aplica_Fisico'.
2. Diagnóstico de Valores Atípicos (1.5 x IQR):

Variable Analizada	Q1	Mediana	Q3	IQR	Lim. Sup.	Outliers	Fraude Normal	Fraude Outliers	Lift
transactions_last_1h	0.00	0.00	1.00	1.00	2.50	8,990 (8.99%)	1.71%	5.57%	3.26x

Variable Analizada	Q1	Mediana	Q3	IQR	Lim. Sup.	Outliers	Fraude Normal	Fraude Outliers	Lift
amount_last_1h	0.00	0.00	100.01	100.01	250.03	11,150 (11.15%)	1.85%	3.71%	2.01x
amount_vs_avg_ratio	0.21	0.58	1.66	1.45	3.84	11,309 (11.31%)	1.88%	3.44%	1.83x
distance_from_last_tx_km	5.20	13.30	31.90	26.70	71.95	15,617 (15.62%)	1.85%	3.18%	1.72x
transaction_amount	21.28	52.26	129.72	108.44	292.38	9,959 (9.96%)	1.95%	3.02%	1.55x

---

3.3 Etapa 4: Transformación e Ingeniería de Características

Se diseñaron 8 variables derivadas para capturar señales débiles de fraude:

Variable Creada	Tipo de Variable	Fórmula
velocity_tx_ratio_1h_24h	Numérica	Transacciones (1h) / (Transacciones (24h) + 1)
velocity_amt_ratio_1h_24h	Numérica	Monto (1h) / (Monto (24h) + 1)
credit_utilization_ratio	Numérica	Monto Transacción / (Límite de Crédito + 1)
zscore_amount_30d	Numérica	(Monto Actual - Media 30d) / (Desviación 30d + 1)
security_factors_count	Numérica	Tarjeta Presente + Chip + PIN
is_night_tx	Booleana	1 si Hora es <= 4
is_new_account	Booleana	1 si Antigüedad Días es <= 90
composite_risk_index	Numérica	Acumulador ponderado de 10 señales débiles concurrentes (eleva la tasa de fraude desde 0.04% en nivel 0 hasta 20.11% en nivel >= 5)

Posteriormente se aplicó Partición Estratificada 80/20 seguida de compresión logarítmica y RobustScaler ajustado exclusivamente sobre X_train.

3.4 Etapa 5 y Etapa 6: Minería de Datos y Evaluación Comparativa

- Detección de Anomalías (IsolationForest): En el conjunto de prueba, las 665 instancias etiquetadas como anómalas presentaron una tasa de fraude del 7.07% frente al 1.88% de las normales (3.75x Lift).
- Selección Estadística y Balanceo SMOTE: Se seleccionaron las 45 características más informativas y se aplicó SMOTE únicamente en X_train.

Resultados de Modelos Evaluados:

Modelo	Umbral	Accuracy	Precision	Recall	F1-Score	ROC-AUC	PR-AUC	Fraude Dtectados	Omitidos
Baseline Mayoritario (Dummy)	0.50	0.9795	0.0000	0.0000	0.0000	0.5000	0.0205	0	411
Regresión Logística	0.35	0.8987	0.0903	0.4331	0.1495	0.8152	0.0964	178	233

Modelo	Umbral	Accuracy	Precision	Recall	F1-Score	ROC-AUC	PR-AUC	Fraude Dtectados	Omitidos
(SMOTE)									
Árbol de Decisión (SMOTE)	0.30	0.9367	0.1349	0.3844	0.1997	0.8103	0.1109	158	253
Random Forest (SMOTE)	0.50	0.8786	0.0895	0.5353	0.1534	0.8292	0.1039	220	191
Gradient Boosting (SMOTE)	0.15	0.9313	0.1288	0.4063	0.1956	0.8379	0.1369	167	244

3.5 Etapa 7: Interpretación del Conocimiento y Reglas de Decisión

ID Regla	Condicion Logica	Fraudes Detectados	Precisión (Tasa de Fraude)	Lift sobre Base (`2.055%`)	Acción Bancaria Recomendada
Regla 1	`high_risk_country == 1` y `card_present == 0` y `transactions_last_1h >= 3`	91	33.83%	16.46x	Bloqueo preventivo
Regla 2	`high_risk_country == 1` y `account_age_days <= 90`	131	23.19%	11.28x	Bloqueo + KYC
Regla 3	`transaction_hour <= 4` y `international_transaction == 1` y `card_present == 0`	114	12.64%	6.15x	Reto 3D-Secure
Regla 4	`amount_vs_avg_ratio > 4.8` y `num_chargebacks_ever >= 2` y `card_present == 0`	62	10.15%	4.94x	Autenticación 2FA
Regla 5	`composite_risk_index >= 5`	575	20.11%	9.79x	Escalamiento a motor ML + 2FA

4. Artefactos Generados en results/

- 01_desbalance_y_tipologias.png: Desbalance estadístico y distribución por modalidad de fraude.
- 02_outliers_iqr_y_isolation_forest.png: Curvas de densidad del puntaje IsolationForest y tasa de fraude por nivel de composite_risk_index.
- 03_seleccion_variables_importancia.png: Ranking de importancia de variables (Random Forest) y estadístico Chi-Cuadrado.
- 04_comparativa_modelos_curvas_roc_pr.png: Curvas ROC y Precision-Recall comparativas en el conjunto de prueba.
- 05_matrices_confusion.png: Matrices de confusión de los modelos supervisados con SMOTE.
- 06_arbol_reglas_decision.png: Árbol de decisión en unidades originales para extracción de reglas de negocio.
- resumen_modelos_kdd.csv, reglas_negocio_validadas.csv y reglas_decision_fraude.txt.