GUÍA DE ESTUDIO, EXPOSICIÓN Y DEFENSA ORAL (MODO PROFESOR)

MANUAL DE DOMINIO Y DEFENSA DEL PROYECTO KDD

¿Para qué sirve este documento?

1. **Explicación en lenguaje sencillo y con analogías** de todo lo que hicimos en el Avance del Proyecto Integrador bajo la metodología KDD.
2. **Acordeón de las 10 Cifras de Oro** y guion de 2 minutos para iniciar tu presentación.
3. **Simulador de Examen (20 Preguntas del Profesor con Respuestas Nivel 100)** sobre diagnóstico, limpieza, outliers, ingeniería de características, escalamiento, los 2 métodos de filtro, partición 80/20, validación cruzada de 5 particiones y prevención de *Data Leakage*.



Universidad de Guadalajara — CUGDL

Alumno: Roberto Alejandro Chagra Martínez | Materia: Data Mining y Knowledge Discovery

PARTE 1: VISIÓN GENERAL PARA TU EXPOSICIÓN

1. Cómo Explicar tu Proyecto en 2 Minutos

🎙️ GUION DE APERTURA SUGERIDO (DILO CON TUS PROPIAS PALABRAS AL EMPEZAR A EXPONER):

*"En este avance aplicamos la **metodología KDD (Knowledge Discovery in Databases)** a un conjunto de **100,000 transacciones con tarjeta de crédito y 43 variables** para resolver el problema de detección automatizada de fraude. Nuestro gran reto es que solo el **2.055% de las operaciones son fraude (2,055 casos)** pero provocan una pérdida de **$279,842 dólares**. Durante la preparación de datos descubrimos que los **41,709 valores nulos en la columna** `browser` no eran errores, sino compras físicas en terminales POS y cajeros ATM, por lo que los imputamos como* `'No_Aplica_Fisico'` *para no borrar el canal presencial. Además, demostramos que los valores atípicos concentran hasta **3.26 veces más fraude**, así que los conservamos y estabilizamos con logaritmos y* `RobustScaler`*. Creamos **8 nuevas variables de negocio** —destacando un índice compuesto de riesgo que resultó ser la variable #1 más potente—, comparamos **dos métodos de filtro (ANOVA F/Chi² e Información Mutua)** logrando reducir de **91 a 30 características**, y validamos todo con **Validación Cruzada Estratificada de 5 Particiones sin Data Leakage**, alcanzando un **ROC-AUC de 0.8523**."*

CONCEPTO CLAVE

¿Qué es la Metodología KDD explicada de forma sencilla?

Imagina que los datos crudos son **mineral recién sacado de una mina** y el conocimiento final es un **lingote de oro puro**. Mucha gente comete el error de meter la piedra sucia directo al algoritmo de Machine Learning. La metodología **KDD (Fayyad et al., 1996)** nos dice que el modelado es apenas un paso de una cadena de 5 etapas: **(1) Selección** (separar las variables que sí existen en tiempo real y quitar trampas post-evento), **(2) Preprocesamiento/Limpieza** (entender por qué faltan datos y por qué hay valores extremos antes de borrar nada), **(3) Transformación e Ingeniería** (crear pistas nuevas, codificar texto a números y escalar sin mezclar entrenamiento con prueba), **(4) Reducción por Filtros** (quedarnos solo con las 30 mejores pistas de las 91) y **(5) Minería y Evaluación** (probar en 5 particiones estratificadas que el resultado es real y sin fuga de información).

📌 Las 10 Cifras de Oro que debes recordar en clase:

1. Tamaño del Dataset:
100,000 filas × 43 columnas (fuente: Kaggle, calibrado con Reserva Federal, Nilson, FICO y BCE).

2. Variable Objetivo (`is_fraud`):
97,945 legítimas (97.945%) vs. **2,055 fraudes (2.055%)**. Desbalance **1 : 47.66** y pérdida de **$279,842.20 USD**.

3. Valores Faltantes (Nulos):
41,709 nulos (41.71%) solo en `browser` . El 100% son canales físicos: **35,777 POS (tienda) + 5,932 ATM (cajero)**.

4. Duplicados e Inconsistencias:
0 duplicados y **0 errores de rango**. Se quitaron **8 columnas** (2 por *Target Leakage* + 6 IDs), quedando **35 columnas**.

5. Valores Atípicos (1.5 × IQR):
No son errores: en `transactions_last_1h > 2.5` el fraude sube de 1.71% a **5.57% (3.26 veces más fraude)**. Se conservaron todos.

6. Ingeniería de Características:
Creamos **+8 variables derivadas**. La mejor fue `composite_risk_index` (sube el fraude de **0.04% a 87.50%**).

7. Partición Entrenamiento / Prueba:
80% Train (80,000 filas, 1,644 fraudes = 2.0550%) y **20% Test (20,000 filas, 411 fraudes = 2.0550%)** con `stratify=y` .

8. Codificación y Escalamiento:
`OneHotEncoder(drop='first')` en 8 categóricas expandió a **91 columnas**. Escalamiento con `np.log1p` + `RobustScaler` .

9. Dos Métodos de Filtro:
ANOVA F / χ^2 vs. **Información Mutua**. Coincidieron en **20 de su Top 25 (80%)**. Unión = **30 variables (-67% dim)**.

10. Validación Cruzada 5-Fold sin Leakage:
Cada pliegue: **64,000 train / 16,000 val**. Regresión Logística logró **ROC-AUC = 0.8523 ± 0.0104** y **Recall = 76.09%**.

2. Entendiendo el Diagnóstico y la Limpieza sin Tecnicismos

ANALOGÍA 1: EL GUARDIA DORMIDO

¿Por qué el Desbalance (97.945% vs 2.055%) causa la "Paradoja de la Exactitud"?

Imagina que contratas a un guardia de seguridad para vigilar una tienda donde 98 de cada 100 clientes son honestos y 2 son ladrones. Si el guardia se queda dormido todo el día y dice *"todos son honestos"*, ¡tendrá un **98% de aciertos (Accuracy)**! Pero como detector de ladrones es inútil (**Recall = 0%**). Por eso en este proyecto no nos dejamos engañar por el Accuracy global y usamos métricas que evalúan qué tan bien atrapamos al 2.055% de fraudes: **ROC-AUC**, **PR-AUC** (precisión vs sensibilidad) y **Recall**.

ANALOGÍA 2: COMPRAR EN EL OXXO VS. COMPRAR EN AMAZON

¿Por qué hay 41,709 valores nulos en `browser` y por qué fue vital NO borrarlos?

Al revisar las 43 columnas, vimos que 42 estaban completas al 100%, pero la columna `browser` (navegador web: Chrome, Safari, Edge...) tenía **41,709 celdas vacías (41.71%)**. Un principiante habría aplicado `df.dropna()` (borrando casi la mitad de la base de datos) o habría rellenado todo con la moda (`'Chrome'`).
Nosotros investigamos primero: cruzamos esos 41,709 registros contra la columna `transaction_channel` y descubrimos que **35,777 eran compras en tienda física (`In-store` con terminal POS)** y **5,932 eran retiros en cajero automático (`ATM`)**.
¡Cuando metes tu tarjeta en un cajero automático o pasas el plástico en una terminal bancaria física, no usas ningún navegador web! A eso se le llama **Ausencia Estructural**.
· Si borrábamos esas filas, habríamos dejado al banco ciego ante cualquier clonación de tarjeta física (**Sesgo de Selección**).
· Si poníamos `'Chrome'` , habríamos mentido diciendo que los cajeros automáticos usan Google Chrome.
· **Nuestra solución:** Rellenar con la etiqueta `'No_Aplica_Fisico'` . Así conservamos las 100,000 filas y creamos una pista valiosísima.

ANALOGÍA 3: APOSTAR VIENDO EL PERIÓDICO DE MAÑANA

¿Por qué eliminamos `fraud_type` y `fraud_amount_lost` (Target Leakage)?

En la base de datos vienen dos columnas llamadas `fraud_type` (que dice *'Legitimate'* cuando no hubo fraude o el tipo de fraude cuando sí hubo) y `fraud_amount_lost` (que vale `$0` en compras legítimas y mayor a `$0` en fraudes). En la vida real, cuando un cliente pasa su tarjeta y el banco tiene milisegundos para decidir si aprueba o rechaza el cargo, **el banco todavía no sabe cuánto dinero perdió ni qué tipo de fraude fue**; eso se llena semanas después cuando el cliente reclama. Si dejábamos esas dos columnas, el modelo aprendería el truco trivial: *"Si dinero perdido > 0, entonces es fraude"*. A eso se le llama **Fuga de Información de la Variable Objetivo (Target Leakage)**. También quitamos 6 identificadores (IDs de transacción, cliente, tarjeta, comercio, fecha texto y estado) porque un código como `TXN_0001` no sirve para predecir a nuevos clientes. Así pasamos de **43 a 35 columnas limpias**.

ANALOGÍA 4: LA ALARMA DE INCENDIOS

¿Por qué hicimos el análisis de Outliers (1.5 × IQR) pero decidimos NO eliminarlos?

Usamos la fórmula de los cuartiles de Tukey (*[Q1 - 1.5 × IQR, Q3 + 1.5 × IQR]*) porque las compras con tarjeta no siguen una campana normal perfecta, sino que tienen "cola larga" a la derecha. Encontramos entre un 8.99% y un 15.62% de valores extremos (por ejemplo, hacer más de 2.5 compras en una sola hora o gastar más de $250 dólares en una hora).
Pero cuando calculamos el porcentaje de fraude dentro de esos outliers (lo que llamamos **Lift de Fraude**), descubrimos que hacer muchas compras en 1 hora tiene **5.57% de fraude frente a 1.71% en el rango normal (¡3.26 veces más probabilidad de fraude!)**. Eliminar los outliers en un problema de fraude sería como apagar una alarma de incendios justo cuando detecta temperaturas de 400 °C diciendo *"esa temperatura es atípica, bórrala"*. Por eso decidimos **conservar el 100% de los outliers** y domar su tamaño en la siguiente etapa usando logaritmos y `RobustScaler` .

PARTE 3: EXPLICACIÓN SENCILLA PASO A PASO (FASES III, IV Y V KDD)

3. Ingeniería, Escalamiento, Filtros y Validación

FASE III KDD — INGENIERÍA DE CARACTERÍSTICAS

¿Qué son las 8 Variables Derivadas que creamos y por qué ayudaron tanto?

Un ladrón astuto trata de no llamar la atención en una sola variable, pero deja "pistas combinadas". Creamos 8 variables nuevas usando matemáticas simples:

· **1 y 2. Ratios de aceleración (** `velocity_tx_ratio_1h_24h` **y** `velocity_amt_ratio_1h_24h` **):** Dividen las compras/gasto de la última hora entre las de las últimas 24 horas. Si alguien hizo hoy 5 compras y las 5 fueron en los últimos 10 minutos, el ratio se acerca a 1.0 (ataque de ráfaga o *card testing*).

· **3. Presión de línea (** `credit_utilization_ratio` **):** Divide el monto de la compra entre el límite de crédito total.

· **4. Z-Score personal de 30 días (** `zscore_amount_30d` **):** Compara el monto actual contra el promedio y desviación estándar de los últimos 30 días *de ese mismo cliente*. Así sabemos si $500 USD es normal para un empresario pero rarísimo para un estudiante.

· **5. Escudo de seguridad (** `security_factors_count` **):** Suma `card_present + used_chip + used_pin` (va de 0 a 3). Demostramos que tener los 3 factores baja el fraude de **2.96% a 0.81% (-72.6%)**.

· **6 y 7. Banderas de madrugada (** `is_night_tx` **, 00–04h) y cuenta nueva (** `is_new_account` **, ≤90 días):** Triplican y duplican el riesgo de fraude.

· **8. Semáforo acumulador (** `composite_risk_index` **):** Suma 10 alertas débiles al mismo tiempo. Cuando vale 0, el fraude es **0.04%**; cuando llega a 8, el fraude es **87.50%**. ¡Fue la variable #1 de todo el proyecto!

FASE III KDD — CODIFICACIÓN Y ESCALAMIENTO

¿Cómo convertimos texto a números y cómo escalamos sin distorsionar los datos?

· **Codificación Categórica (** `OneHotEncoder(drop='first')` **):** Teníamos 8 columnas de texto nominal (país, categoría de tienda, navegador, canal, dispositivo, día, género, correo). Si usáramos `LabelEncoder` (1=México, 2=Francia, 3=Nigeria), el modelo creería que México + Francia = Nigeria. Con *One-Hot Encoding* creamos columnas binarias de 0 y 1 para cada opción (quitando la primera con `drop='first'` para no repetir información redundante), pasando de 42 a **91 columnas**.

· **Escalamiento Híbrido (** `np.log1p` **+** `RobustScaler` **):** Primero aplicamos $ln(1 + x)$ a las 6 variables de montos y distancias para comprimir los números gigantes, y luego `RobustScaler`, que resta la **Mediana** y divide entre el **IQR**. A diferencia de `StandardScaler` (que usa promedio y se descontrola con los outliers), la mediana y el IQR son inmunes a valores extremos.

FASE III KDD — DOS MÉTODOS DE FILTRO

¿Por qué comparamos ANOVA F / Chi² contra Información Mutua?

Tener 91 columnas mete mucho ruido (días de la semana o dominios de correo que no tienen nada que ver con el fraude). Por eso contratamos a "dos jueces matemáticos" para calificar las 91 variables solo en entrenamiento:

· **Filtro 1 (Prueba F de ANOVA** `f_classif` **/ Chi²** `chi2` **):** Es un juez **lineal**; busca variables donde el promedio en fraudes sea muy distinto al promedio en compras legítimas.

· **Filtro 2 (Información Mutua de Shannon** `mutual_info_classif` **):** Es un juez **no lineal basado en entropía**; detecta curvas, escalones y umbrales aunque no sean una línea recta.

· **El gran hallazgo:** Ambos jueces coincidieron en **20 de sus 25 mejores variables (80% de consenso)** y ambos pusieron en el **#1 a** `composite_risk_index`. Pero Información Mutua rescató a `account_age_days` (que estaba en el lugar #31 en ANOVA F y subió al **#14 en Información Mutua** porque el riesgo de fraude da un salto brusco en cuentas de ≤90 días). Uniendo los Top 25 de ambos nos quedamos con las **30 mejores características** (reducción del 67%).

FASES IV Y V KDD — PARTICIÓN 80/20, 5-FOLD CV Y CERO DATA LEAKAGE

¿Cómo garantizamos Cero Fuga de Información (Data Leakage)?

Aplicamos un **doble candado**: (1) Primero dividimos el dataset en **80% Entrenamiento (80,000 filas)** y **20% Prueba (20,000 filas)** con `stratify=y` (para que ambos tengan exactamente 2.0550% de fraude) y guardamos el 20% bajo llave. (2) Luego, dentro del 80% de entrenamiento aplicamos **Validación Cruzada Estratificada de 5 Particiones (**`StratifiedKFold(n_splits=5)` **)**: en cada vuelta entrenamos con **64,000 filas** y validamos con **16,000 filas**, asegurándonos de que el `OneHotEncoder`, el `RobustScaler` y el selector de 30 variables se ajusten (`.fit_transform()`) **únicamente con las 64,000 filas de esa vuelta**.

4. Preguntas del Profesor: KDD, Diagnóstico y Limpieza

👩‍🏫 Pregunta 1: "¿Por qué dices que tu trabajo sigue la metodología KDD y qué diferencia hay entre KDD y simplemente entrenar un algoritmo de Machine Learning?"

🎯 Qué evalúa el profesor: Que comprendas que Minería de Datos (Data Mining) es solo un paso dentro del proceso KDD de Fayyad et al. (1996).

Respuesta: "Profesora, en la metodología KDD propuesta por Fayyad, Piatetsky-Shapiro y Smyth, el ajuste de un algoritmo es apenas la cuarta etapa. KDD comprende cinco fases completas: **(1) Selección de datos**, **(2) Preprocesamiento y limpieza**, **(3) Transformación y reducción**, **(4) Minería de datos** y **(5) Interpretación/Evaluación**. Si hubiéramos metido las 43 columnas crudas directo a un clasificador, el modelo habría fallado o hecho trampa por tres razones: habría sufrido *Target Leakage* con las columnas post-evento, habría perdido el 41.7% de los datos por los nulos en `browser` y se habría saturado con 61 variables dummy ruidosas. Seguir KDD nos permitió transformar datos crudos en un subconjunto limpio, compacto y validado de 30 características."

👩‍🏫 Pregunta 2: "Tienes 41,709 valores faltantes (41.71%) en la columna `browser`. ¿Por qué no borraste esa columna o esas filas con `dropna()`, o por qué no imputaste con la moda que era `'Chrome'`?"

🎯 Qué evalúa el profesor: Tu capacidad para distinguir un nulo aleatorio (MCAR) de una Ausencia Estructural y evitar el Sesgo de Selección.

Respuesta: "Porque antes de limpiar hicimos un diagnóstico cruzado de `browser` contra el canal de transacción y el dispositivo. Descubrimos que el **100% de esos 41,709 nulos pertenecen a canales físicos**: 35,777 son compras en tienda física (`POS Terminal`) y 5,932 son retiros en cajero automático (`ATM`), mientras que los canales digitales (`Online` y `Mobile App`) tienen cero nulos. Por lo tanto, no es un error de captura, sino una **Ausencia Estructural** porque un cajero o terminal POS no usa navegador web. Si aplicábamos `dropna()` habríamos eliminado el 100% de las operaciones físicas del banco provocando un grave **Sesgo de Selección**; y si imputábamos la moda (`'Chrome'`) habríamos falseado los datos diciendo que los cajeros usan Chrome. Imputar `'No_Aplica_Fisico'` conservó las 100,000 filas y creó una variable indicadora que terminó en el Top 7 de Información Mutua."

👩‍🏫 Pregunta 3: "¿Por qué eliminaste las variables `fraud_type` y `fraud_amount_lost` durante la limpieza si estaban directamente relacionadas con el fraude?"

🎯 Qué evalúa el profesor: El concepto de causalidad temporal y Fuga de Información de la Variable Objetivo (Target Leakage).

Respuesta: "Precisamente porque son variables **post-evento** que causan **Target Leakage (fuga de la variable objetivo)**. Cuando una transacción ocurre en tiempo real, el sistema debe predecir si es fraude antes de autorizarla; en ese instante nadie sabe cuál fue la modalidad confirmada (`fraud_type`) ni cuánto dinero se perdió (`fraud_amount_lost`). Además, en nuestra auditoría comprobamos que `fraud_amount_lost > 0` ocurre única y exclusivamente cuando `is_fraud == 1`. Dejarlas habría dado un modelo con 100% de exactitud ficticia en papel pero inservible en producción."

👩‍🏫 Pregunta 4: "Hiciste toda una tabla de detección de valores atípicos con el criterio 1.5 × IQR de Tukey, pero al final no eliminaste ni recortaste ningún outlier. ¿Entonces para qué sirvió ese diagnóstico?"

🎯 Qué evalúa el profesor: Que entiendas por qué en detección de anomalías Outlier ≠ Error y cómo ese diagnóstico guió el escalamiento.

Respuesta: "El diagnóstico de outliers sirvió para tomar dos decisiones críticas basadas en evidencia: Primero, al calcular la tasa de fraude dentro de los outliers (el *Lift de Fraude*), demostramos que en variables como `transactions_last_1h > 2.5` la probabilidad de fraude es de **5.57% contra 1.71% en el rango normal (3.26 veces más fraude)**. Eso probó científicamente que los outliers no son errores de captura, sino ataques reales de velocidad, por lo que borrarlos o truncarlos (*Winsorizing*) mutilaría la señal de fraude. Segundo, saber que entre el 9% y el 15.6% de los datos son outliers nos obligó a descartar `StandardScaler` o `MinMaxScaler` y elegir en su lugar `np.log1p` + `RobustScaler` en la fase de transformación."

👩‍🏫 Pregunta 5: "¿Por qué usaste el método de Tukey (1.5 × IQR) para diagnosticar valores atípicos en vez de la regla de la desviación estándar (μ ± 3σ)?"

🎯 Qué evalúa el profesor: Fundamentos estadísticos sobre distribuciones asimétricas (sesgadas).

Respuesta: "Porque la regla de $\mu \pm 3\sigma$ asume que la variable sigue una distribución Normal (gaussiana) simétrica, y tanto la media μ como la desviación estándar σ se ven infladas por los propios valores extremos. En cambio, variables financieras como `transaction_amount` tienen una fuerte asimetría positiva. El método de Tukey usa los cuartiles *Q1* y *Q3* (*IQR = Q3 - Q1*), que son estadísticos de orden no paramétricos que no se distorsionan por las colas pesadas."

5. Preguntas del Profesor: Transformación e Ingeniería

👩‍🏫 Pregunta 6: "¿Por qué aplicaste `OneHotEncoder(drop='first')` a las 8 variables categóricas en vez de `OrdinalEncoder` o `LabelEncoder`, y por qué subieron tus columnas de 42 a 91?"

🎯 Qué evalúa el profesor: Que sepas distinguir variables nominales de ordinales y qué es la trampa de las variables dummy.

Respuesta: "Las 8 variables categóricas de nuestro dataset (como país del comercio, categoría comercial, canal o navegador) son estrictamente **nominales**: no existe un orden natural entre Francia, Japón o Nigeria. Si aplicábamos `LabelEncoder` asignando 0, 1, 2..., estaríamos inventando una jerarquía y distancia matemática falsa. Con `OneHotEncoder` creamos una columna binaria (0 o 1) para cada categoría. Usamos el parámetro `drop='first'` para eliminar una categoría de referencia por cada variable (pasando de 42 a 91 columnas en lugar de 99) y así evitar la **multicolinealidad perfecta (trampa de las variables dummy)**, que haría singular la matriz de covarianza en modelos lineales."

👩‍🏫 Pregunta 7: "¿Por qué combinaste `np.log1p` y `RobustScaler` para escalar las variables numéricas? ¿Y por qué no escalaste las 65 variables binarias?"

🎯 Qué evalúa el profesor: Dominio técnico del escalamiento ante colas pesadas y respeto por la naturaleza de variables dummy.

Respuesta: "En las 6 variables de montos y distancias había valores desde $0 hasta $4,482 USD. Primero aplicamos `np.log1p` (*ln(1 + x)*) porque comprime órdenes de magnitud exponenciales y transforma una distribución sesgada en una campana casi simétrica, con la ventaja de que en *x = 0* vale *ln(1) = 0* (no se indetermina como *ln(0)*). Después aplicamos `RobustScaler` a las 26 variables numéricas, el cual resta la mediana y divide entre el rango intercuartílico (*z = (x - Q2) / IQR*), dejando todas las variables en la misma escala sin que los outliers afecten el centrado. No escalamos las 65 variables binarias porque ya están en *{0, 1}*, que representa ausencia o presencia exacta de la categoría."

👩‍🏫 Pregunta 8: "En tu tabla de escalamiento reportas que la mediana de `transaction_amount` en entrenamiento quedó en `0.0000`, pero en el conjunto de prueba quedó en `-0.0014`. ¿Por qué en prueba no dio cero exacto?"

🎯 Qué evalúa el profesor: ¡Pregunta trampa clásica! Quiere ver si sabes cómo se comprueba matemáticamente que NO hubo Data Leakage.

Respuesta: "¡Ese `-0.0014` es precisamente la prueba matemática de que **no cometimos Data Leakage**! El `RobustScaler` calculó la mediana ($52.27 USD) exclusivamente con los 80,000 registros de `X_train` mediante `.fit_transform()`, por lo que en entrenamiento la mediana escalada es exactamente `0.0000`. Luego, al transformar los 20,000 datos de `X_test` usando solo `.transform()`, se les restó la mediana de entrenamiento (y no la suya propia). Como la mediana natural de prueba varía ligeramente por muestreo, el resultado proyectado es `-0.0014`. Si hubiera salido `0.0000` exacto en ambos, significaría que escalamos mal antes de dividir."

👩‍🏫 Pregunta 9: "Explícame dos de las 8 variables derivadas que creaste en la Ingeniería de Características y por qué tuvieron tanto éxito."

🎯 Qué evalúa el profesor: Capacidad de conectar fórmulas matemáticas con el problema real del negocio bancario.

Respuesta: "La primera es `composite_risk_index`, un índice que suma 10 señales débiles (país de alto riesgo, compra internacional, sin tarjeta presente, alta velocidad en 1h, contracargos previos, rechazos previos, madrugada, cuenta nueva, monto mayor a 4.8x su promedio y salto geográfico > 800 km). Demostramos que cuando este índice vale 0 la tasa de fraude es apenas **0.04%**, pero cuando llega a 8 la tasa de fraude sube a **87.50%**, convirtiéndose en el predictor #1 de todo el dataset. La segunda es `security_factors_count` (`card_present + used_chip + used_pin`), que mide de 0 a 3 el blindaje físico de la compra y demostró reducir la tasa de fraude en un **72.6%** (de 2.96% con 0 factores a 0.81% con los 3 factores)."

👩‍🏫 Pregunta 10: "Tu variable `zscore_amount_30d` usa una media y una desviación estándar en su fórmula: `(amount - avg_30d) / (std_30d + 1)`. ¿Eso no causa Data Leakage entre filas?"

🎯 Qué evalúa el profesor: Diferenciar entre estadísticos históricos individuales por cliente vs. estadísticos globales de toda la columna.

Respuesta: "No causa ningún *Data Leakage* porque `avg_transaction_amount_30d` y `std_transaction_amount_30d` no son promedios de toda la base de datos ni incluyen transacciones futuras; son atributos históricos individuales de los 30 días pasados de ese tarjetahabiente que ya vienen registrados en la misma fila al momento de la compra. Además, sumamos `+ 1` en el denominador para evitar divisiones entre cero si un cliente tuvo desviación estándar cero en su mes previo."

6. Preguntas del Profesor: Dos Métodos de Filtro

👩‍🏫 Pregunta 11: "¿Qué es un método de filtro para selección de características y por qué elegiste específicamente ANOVA F / Chi² e Información Mutua?"

🎯 Qué evalúa el profesor: Que domines la teoría de selección de características (Filter vs Wrapper/Embedded) y la justificación de ambos métodos.

Respuesta: "Un método de filtro evalúa la relevancia estadística intrínseca de cada característica respecto a la variable objetivo `is_fraud` sin entrenar ningún clasificador, por lo que es rapidísimo y no se sobreajusta a un modelo en particular. Elegimos dos métodos matemáticamente complementarios: El **Filtro 1 (Prueba F de ANOVA `f_classif` junto con Chi-Cuadrado `chi2` en binarias)** es un método **paramétrico lineal** que mide qué tan separadas están las medias inter-clase respecto a la varianza intra-clase. El **Filtro 2 (Información Mutua de Shannon `mutual_info_classif`)** es un método **no paramétrico basado en teoría de la información** que mide cuánto se reduce la incertidumbre (entropía) de `is_fraud` al conocer la variable, siendo capaz de detectar relaciones no lineales y umbrales escalonados."

👩‍🏫 Pregunta 12: "Al comparar los resultados de ambos métodos de filtro sobre las 91 variables, ¿a qué conclusión llegaste? ¿Se contradicen?"

🎯 Qué evalúa el profesor: Tu capacidad de comparar e interpretar críticamente las salidas de ambos métodos (punto explícito de la rúbrica).

Respuesta: "Lejos de contradecirse, mostraron un **consenso estructural del 80.0%**: **20 de las 25 mejores variables fueron exactamente las mismas en ambos métodos**. Ambos colocaron en el **puesto #1 absoluto a nuestra variable derivada** `composite_risk_index` (*F = 3,719.82* e Información Mutua *= 0.01945 nats*), seguida en los primeros lugares por `high_risk_country`, `international_transaction`, `distance_from_home_km`, `merchant_country_USA` y `security_factors_count`. Y el 20% donde difirieron fue sumamente enriquecedor porque cada filtro aportó su especialidad matemática."

👩‍🏫 Pregunta 13: "Dame un ejemplo concreto de tu tabla donde el Filtro 1 (ANOVA F) y el Filtro 2 (Información Mutua) hayan dado rankings muy distintos y explícame por qué."

🎯 Qué evalúa el profesor: Esta es la respuesta que distingue un trabajo sobresaliente de uno promedio.

Respuesta: "Tenemos dos ejemplos muy claros en sentidos opuestos:
1) **Lo que rescató Información Mutua (No Lineal):** La variable `account_age_days` (antigüedad de la cuenta en días) quedó en el puesto **#31 en ANOVA F** (*F = 79.13*), pero subió hasta el **puesto #14 en Información Mutua**. ¿Por qué? Porque el riesgo de fraude no baja en línea recta desde el día 1 hasta los 10 años, sino que tiene un **escalón brusco no lineal** en cuentas menores a 90 días (fraude por identidad sintética) y después se vuelve plano. ANOVA F busca una línea recta y la castiga, mientras que la entropía de Información Mutua detecta el escalón perfectamente.
2) **Lo que priorizó ANOVA F / Chi² (Lineal):** Indicadores binarios de países de riesgo como China (#6 en F vs #18 en MI), Rumania (#7 en F vs #21 en MI) y Nigeria (#8 en F vs #23 en MI). Como ocurren en pocas transacciones del total de 80,000, su entropía global es moderada, pero cuando ocurren tienen una tasa de fraude altísima que dispara el estadístico *F* y χ^2."

👩‍🏫 Pregunta 14: "¿Por qué seleccionaste finalmente 30 características de las 91 y qué variables fueron las que se descartaron?"

🎯 Qué evalúa el profesor: Criterio de corte en reducción de dimensionalidad.

Respuesta: "Tomamos la **unión de los Top 25 de ambos métodos de filtro** (*Top 25 F* ∪ *Top 25 MI*). Como 20 variables estaban en ambos Top 25, sumadas a las 5 exclusivas de ANOVA F y a las 5 exclusivas de Información Mutua, obtuvimos exactamente **30 características óptimas**. Esto logró una **reducción dimensional del 67.0%**, eliminando 61 variables dummy que tenían *p-valor > 0.05* e Información Mutua cercana a cero (como los días de la semana, el género del cliente, los dominios de correo electrónico y las categorías de comercios comunes)."

👩‍🏫 Pregunta 15: "En tus tablas de selección aparece `browser_No_Aplica_Fisico` en el puesto #7 de Información Mutua y #11 de ANOVA F. ¿Por qué una etiqueta que tú inventaste en la limpieza resultó tan predictiva?"

🎯 Qué evalúa el profesor: Conexión entre la Fase II (Limpieza) y la Fase III (Selección de características).

Respuesta: "Porque más de la mitad de todos los fraudes del dataset (el **51.29%**, 1,054 casos) son de tipo *Card-Not-Present* (compras en línea), mientras que en las compras físicas en tienda y cajero donde `browser_No_Aplica_Fisico = 1` existen protecciones físicas como el chip EMV y el PIN que reducen drásticamente la tasa de fraude. Así, nuestra imputación semántica le dio a los filtros un indicador directo que separa el ecosistema físico del ecosistema digital."

7. Preguntas del Profesor: Validación Cruzada y Leakage

👩‍🏫 Pregunta 16: "¿Cómo realizaste la partición de entrenamiento y prueba y cómo justificas la estrategia utilizada?"

🎯 Qué evalúa el profesor: Proporción 80/20, uso obligatorio de estratificación (`stratify=y`) y orden temporal antes de transformar.

Respuesta: "Utilizamos una **partición aleatoria estratificada 80% Entrenamiento (80,000 filas) y 20% Prueba (20,000 filas)** con `train_test_split(..., test_size=0.20, stratify=y, random_state=42)` ejecutada **antes** de cualquier codificación, escalamiento o selección de variables. Justificamos el uso de `stratify=y` porque, ante una clase minoritaria de apenas 2.055%, una división aleatoria simple podría dejar distinta proporción de fraudes en cada subconjunto; gracias a la estratificación, tanto entrenamiento (1,644 fraudes) como prueba (411 fraudes) conservaron exactamente el **2.0550%** de prevalencia."

👩‍🏫 Pregunta 17: "¿Cómo implementaste la validación cruzada de 5 particiones considerando la naturaleza desbalanceada del problema?"

🎯 Qué evalúa el profesor: Por qué `StratifiedKFold(n_splits=5)` es indispensable frente a `KFold` estándar.

Respuesta: "Implementamos `StratifiedKFold(n_splits=5, shuffle=True, random_state=42)` exclusivamente sobre los 80,000 registros de entrenamiento. Al ser estratificada, divide los 80,000 datos en 5 bloques de 16,000 registros donde cada bloque tiene exactamente entre 328 y 329 fraudes (**2.055%**). En cada una de las 5 iteraciones, **4 bloques (64,000 filas con 1,315 fraudes)** se usan para entrenar y **1 bloque (16,000 filas con 329 fraudes)** se usa para validar, obteniendo el promedio y la desviación estándar de las métricas en las 5 particiones."

👩‍🏫 Pregunta 18: "Si ya habías apartado los 20,000 datos de prueba al inicio, ¿por qué dices que escalar o seleccionar características sobre los 80,000 datos de entrenamiento ANTES de entrar al bucle de 5 particiones causaría Data Leakage?"

🎯 Qué evalúa el profesor: ¡La pregunta máxima sobre prevención de Data Leakage en Validación Cruzada (Cross-Fold Leakage)!

Respuesta: "Porque dentro de la validación cruzada de 5 particiones, en cada vuelta hay 16,000 registros que fungen como 'datos futuros desconocidos' (el pliegue de validación). Si nosotros hubiéramos ajustado el `RobustScaler` o el selector `SelectKBest` sobre los 80,000 registros completos antes del bucle, esos 16,000 registros de validación ya habrían participado en el cálculo de las medianas, de los cuartiles y de los puntajes *F*. Eso se llama **Fuga de Información entre Pliegues (Cross-Fold Data Leakage)**. Para evitarlo al 100%, dentro del bucle `for` ajustamos (`.fit_transform()`) el `ColumnTransformer` y el selector `SelectKBest(k=30)` **únicamente con los 64,000 registros de entrenamiento de ese pliegue** y a los 16,000 de validación solo les aplicamos `.transform()` ."

👩‍🏫 Pregunta 19: "En tus resultados de validación cruzada, la Regresión Logística Balanceada obtuvo un ROC-AUC de 0.8523 y un Recall de 76.09%, superando ligeramente a Random Forest (0.8378). ¿Cómo interpretas eso?"

🎯 Qué evalúa el profesor: Interpretación de resultados conectada con la calidad de la preparación de datos.

Respuesta: "Ese resultado demuestra el éxito de nuestra preparación de datos e ingeniería de características en la Fase III KDD: al haber creado variables como `composite_risk_index` y `security_factors_count` , haber estabilizado las colas con `np.log1p` + `RobustScaler` y haber eliminado 61 columnas de ruido con los filtros, hicimos que el problema fuera altamente separable incluso para un modelo lineal como la Regresión Logística con pesos balanceados (`class_weight='balanced'`), logrando además una desviación estándar mínima entre los 5 pliegues (*± 0.0104*) y un PR-AUC **8.97 veces superior al azar**."

👩‍🏫 Pregunta 20: "Con base en tus conclusiones de esta entrega, ¿qué sigue en la siguiente etapa de tu proyecto integrador?"

🎯 Qué evalúa el profesor: Visión de continuidad hacia el modelado final y reglas de decisión.

Respuesta: "Ahora que contamos con un pipeline libre de *Data Leakage* y las 30 características más informativas validadas en 5-Fold CV, el siguiente paso es entrenar y optimizar los modelos finales de clasificación y detección de anomalías (combinando balanceo sintético *SMOTE* dentro de cada pliegue y ajuste de umbrales de probabilidad óptimos costo-beneficio), evaluar por única vez sobre los 20,000 registros sellados de `X_test` y extraer reglas de decisión interpretables (*SI-ENTONCES*) para el motor antifraude."