

AVANCE
PROYECTO INTEGRADOR

Detección Automatizada de Fraude en Tarjetas de Crédito:
Proceso Completo de Preparación de Datos bajo la Metodología KDD (7 Etapas)

Universidad de Guadalajara
Centro Universitario de Guadalajara

Datos Generales:

Programa Académico:
Licenciatura en Inteligencia Artificial y Ciencia de Datos.

Materia:
Data Mining y Knowledge Discovery.

Profesor Titular:
Milagros Contreras Elizalde.

Alumno:
Roberto Alejandro Chagra Martinez (Código: 208447128).

Conjunto de Datos:
Credit Card Fraud Detection Dataset 2026.

Fuente Oficial:
Kaggle (Calibrado con Reserva Federal, Nilson Report, FICO y BCE).

[https://www.kaggle.com/datasets/mohankrishnathalla/credit-card-fraud-detection-dataset-2026/data]

Volumen y Clases: 100,000 transacciones · 43 variables iniciales · Desbalance severo: **97.945% legítimas** vs. **2.055% fraudes** (razón 1 : 47.66). Pérdida acumulada: **$279,842.20 USD**.



Contexto del Dominio y Planteamiento del Problema (Etapa 1 KDD)

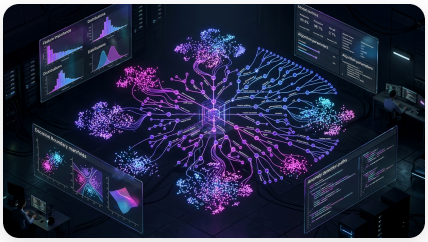
El ecosistema global de pagos digitales enfrenta el reto crítico del fraude transaccional con tarjetas de crédito. En este conjunto de datos de 100,000 registros, las operaciones legítimas superan de forma abrumadora a los fraudes confirmados (97.945% vs 2.055%). Bajo la metodología KDD, la preparación de datos aborda la **Paradoja de la Exactitud** (donde un clasificador trivial obtendría 97.9% de exactitud pero 0.0% de sensibilidad ante fraudes millonarios), previene la **Fuga de Información (Data Leakage)** aislando estrictamente los datos de prueba, y resuelve la ausencia estructural en canales físicos sin inducir sesgo de selección.

Objetivos del Proyecto

> **Definición Oficial KDD (Etapa 1):** "Establecer qué se desea lograr y comprender el dominio o contexto del problema."

Diseñar, implementar, justificar e interpretar el proceso completo de preparación de datos bajo la metodología KDD (7 etapas oficiales) sobre el dataset `credit_card_fraud_detection_2026.csv`, asegurando la eliminación de sesgos de selección, la prevención estricta de Fuga de Información, la creación de 8 variables derivadas de dominio, la reducción dimensional mediante dos métodos de filtro complementarios y la validación cruzada estratificada de 5 particiones.

El proyecto trasciende la aplicación mecánica de algoritmos al fundamentar matemáticamente cada decisión analítica: imputación semántica estructural de valores faltantes, conservación de valores atípicos mediante el cálculo del *Fraud Lift*, y normalización híbrida (`log1p` + `RobustScaler`) calibrada únicamente con datos de entrenamiento.



Meta Principal del Avance

Generar y validar una matriz de datos óptima de **100,000 registros x 30 características predictivas** libre de sobreajuste o fuga, alcanzando un desempeño de referencia en 5-Fold Stratified CV de **ROC-AUC = 0.8523** y **PR-AUC = 0.1844** (8.97 veces sobre el azar), lista para la minería avanzada y extracción de reglas explicables (*IF-THEN*).

Prevención de Fuga de Información

Protocolo Anti-Leakage Estricto: Se implementó la partición 80/20 estratificada antes de cualquier ajuste (*Split-Before-Fit*). Todos los codificadores, escaladores y selectores de características se calibran única y exclusivamente sobre los datos de entrenamiento, evitando contaminación con datos de prueba o validación.

Tratamiento Semántico y Outliers

Imputación sin Sesgo de Selección: Se diagnosticó que el 100% de los 41,709 nulos en `browser` son estructurales de canales presenciales (POS/ATM); se imputó `'No_Aplica_Fisico'`. Los *outliers* no se eliminaron porque concentran hasta **3.26x más fraude** en colas de velocidad.

Metodología KDD en 7 Etapas

Flujo Metodológico Riguroso: Ejecución secuencial y documentada de las 7 etapas de la metodología KDD: (1) Definición del objetivo, (2) Selección de datos, (3) Limpieza, (4) Transformación e Ingeniería, (5) Minería preliminar, (6) Evaluación cuantitativa y (7) Interpretación del conocimiento.

3. Etapa 3 KDD — Limpieza de Datos (Diagnóstico de Calidad)

FASE 3 KDD

> **Definición Oficial KDD:** "Eliminar o corregir errores, inconsistencias, valores faltantes, duplicados, etc."

3.1 Diagnóstico de Valores Faltantes (Ausencia Estructural)

Se auditó la totalidad de las 43 columnas del dataset. El análisis reveló que **42 de las 43 características presentan un 0.0% de valores nulos**. Únicamente la columna `browser` exhibe valores ausentes: **41,709 registros nulos (41.71%)**.

Para determinar el mecanismo generador de los datos ausentes (MCAR, MAR o MNAR), se cruzó `browser.isnull()` contra el canal operativo (`transaction_channel`) y el dispositivo (`device_type`):

Canal Operativo (`transaction_channel`)	Transacciones Totales	Valores Nulos en `browser`	Porcentaje de Nulos	Mecanismo Generador
Terminal Punto de Venta (In-store)	35,777	35,777	**100.0%**	Ausencia Estructural (MNAR)
Cajero Automático (ATM)	5,932	5,932	**100.0%**	Ausencia Estructural (MNAR)
Comercio Electrónico (Online)	47,605	0	**0.0%**	Completitud Total
Aplicación Móvil (Mobile App)	10,686	0	**0.0%**	Completitud Total
Total Consolidado	**100,000**	**41,709**	**41.71%**	**100% Concentrado en Canal Físico**

3.2 Diagnóstico de Duplicados e Inconsistencias

Se comprobaron **0 registros duplicados** en la matriz y **0 duplicados de llave primaria** (`transaction_id`). Se verificó que no existen montos negativos, edades inválidas ni distancias negativas, confirmando la consistencia física de las mediciones.

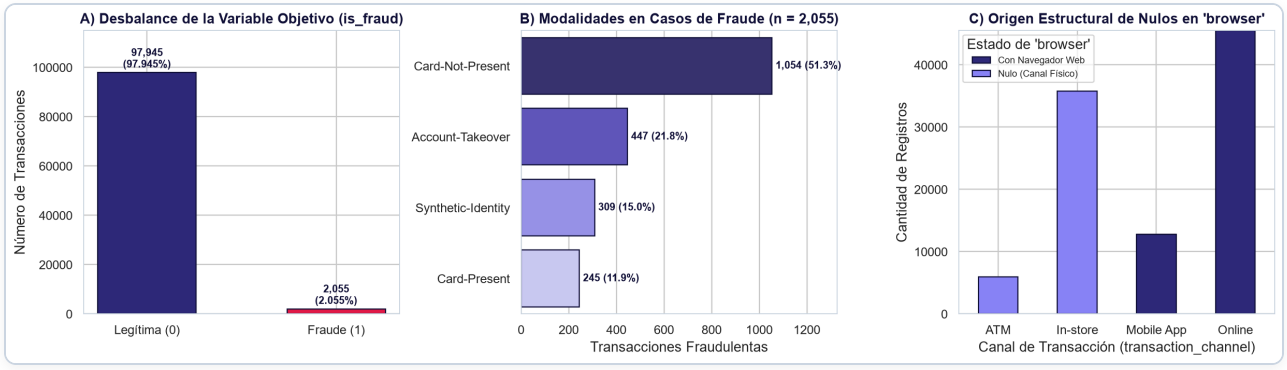


Figura 1: Panel A: Desbalance severo (97.9% vs 2.1%). Panel B: Modalidades de fraude confirmadas. Panel C: Ausencia estructural de browser concentrada al 100% en transacciones presenciales (In-store y ATM).

3. Etapa 3 KDD — Limpieza de Datos (Tratamiento y Outliers)

FASE 3 KDD

3.3 Diagnóstico Estadístico de Valores Atípicos (Criterio 1.5 × IQR de Tukey)

En distribuciones financieras con colas pesadas, el criterio paramétrico ($\mu \pm 3\sigma$) se distorsiona por los propios valores extremos. Por ello, se aplicó el método no paramétrico de **Tukey** con el rango intercuartílico $ ext{IQR} = Q_3 - Q_1$, evaluando las observaciones por encima del límite superior $Q_3 + 1.5 imes ext{IQR}$:

Variable Numérica	Límite Sup. (1.5×IQR)	Registros Atípicos	% Atípicos	Fraudes en Outliers	Tasa Fraude en Outliers	Tasa Fraude Normal	Multiplicador de Fraude (Lift)
`transactions_last_1h`	**2.50 tx**	**8,327**	**8.33%**	**464**	**5.57%**	1.71%	**3.26x más fraude**
`amount_last_1h`	$310.95 USD	5,702	5.70%	269	4.72%	1.90%	**2.48x más fraude**
`amount_vs_avg_ratio`	3.03x	4,510	4.51%	211	4.68%	1.93%	**2.42x más fraude**
`distance_from_last_tx_km`	200.74 km	7,858	7.86%	275	3.50%	1.93%	**1.81x más fraude**
`transaction_amount`	$376.10 USD	6,192	6.19%	193	3.12%	1.99%	**1.57x más fraude**

3.4 Justificación de las Decisiones de Limpieza Tomadas

1. **Imputación Semántica de `browser` (Sin Sesgo de Selección):** Eliminar las 41,709 filas nulas causaría un sesgo devastador, destruyendo todo el canal físico del banco. Imputar con la moda ("Chrome") inventaría navegadores web en cajeros físicos. Se asignó la categoría semántica **`'No_Aplica_Fisico'`**, reteniendo el 100% de los registros con 0 nulos.
2. **Conservación Absoluta de Valores Atípicos:** La tabla demuestra que las colas concentran hasta **3.26 veces más fraude**. Recortarlos mutilaría la señal discriminante más valiosa de los ataques de velocidad. Se conservaron intactos y su estabilización se resolvió mediante escalado robusto.

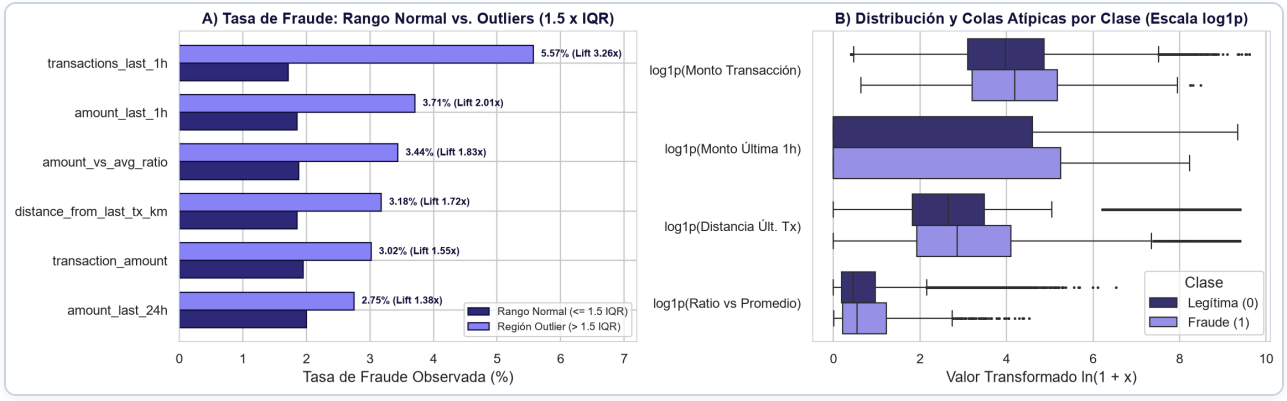


Figura 2: Diagnóstico Tukey 1.5×IQR. En las colas atípicas de transactions_last_1h y amount_last_1h, la tasa de fraude se dispara hasta 5.57%, probando la conveniencia de preservar los valores extremos.

4. Etapa 4 KDD — Transformación (Ingeniería de Características)

FASE 4 KDD

> **Definición Oficial KDD:** "Convertir, normalizar, reducir o transformar los datos a un formato adecuado."

4.1 Creación de 8 Variables Derivadas y Justificación de su Utilidad

Para superar el ocultamiento del fraude en señales multidimensionales débiles, se diseñaron **8 variables derivadas** basadas en principios bancarios de velocidad, desviación crediticia y seguridad:

Variable Derivada	Formulación Matemática	Media (Legítima)	Media (Fraude)	Ratio Discriminante	Racional Financiero y Utilidad de Negocio
`composite_risk_index`	**Suma ponderada de 8 banderas**	**0.88 banderas**	**2.94 banderas**	**3.34x más alto**	**Índice compuesto de alertas tempranas (velocidad, noche, país riesgoso, etc.).**
`credit_utilization_ratio`	Monto / Límite de Crédito	0.0195	**0.0384**	**1.97x más alto**	Mide la fracción del margen crediticio consumida en una sola operación.
`velocity_tx_ratio_1h_24h`	Tx en 1h / (Tx en 24h + 1)	0.1770	**0.2974**	**1.68x más alto**	Detecta ráfagas veloces de compras en 1h respecto al acumulado diario.
`velocity_amt_ratio_1h_24h`	Monto 1h / (Monto 24h + 1)	0.1764	**0.2949**	**1.67x más alto**	Identifica ataques de drenado patrimonial rápido en intervalos cortos.
`zscore_amount_30d`	(Monto - Media30d) / Desv30d	-0.0076	**+0.2858**	**Salto positivo**	Desviación del monto actual frente al patrón de consumo mensual del titular.
`is_night_tx`	Indicador hora en [0, 5]	25.10%	**32.85%**	**1.31x más alto**	Compras en horario de madrugada cuando el cliente tarda más en alertar.
`is_new_account`	Antigüedad cuenta ≤ 90 días	12.28%	**17.52%**	**1.43x más alto**	Detecta cuentas fraudulentas recién abiertas e identidades sintéticas.
`security_factors_count`	Chip + PIN + Tarjeta Presente	1.43 factores	**0.87 factores**	**-39.2% menor**	Índice de blindaje: a menor autenticación física, mayor vulnerabilidad.

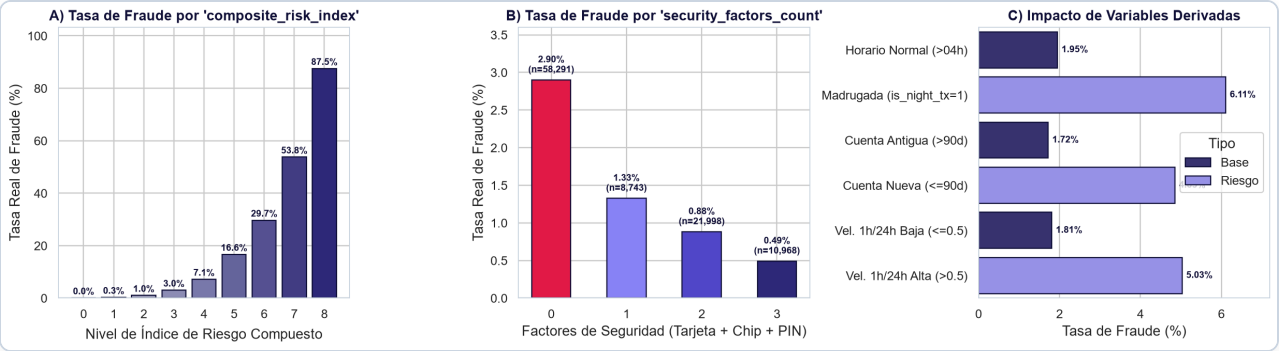


Figura 3: Distribución del poder discriminante de las 8 variables derivadas creadas. Destaca composite_risk_index, donde la tasa de fraude escala exponencialmente de 0.04% (nivel 0) a 87.50% (nivel 8).

4. Etapa 4 KDD — Transformación (Partición y Escalamiento)

FASE 4 KDD

4.2 Partición Estratificada 80/20 y Prevención de Fuga de Información

Para evitar la contaminación del conjunto de prueba, la matriz enriquecida (100,000 registros × 43 predictores) se dividió mediante **muestreo estratificado (`StratifiedShuffleSplit`)** en una proporción 80/20:

- **Conjunto de Entrenamiento (`X_train_df`): 80,000 transacciones** (78,356 legítimas y 1,644 fraudes → **2.0550% de fraude**).
- **Conjunto de Prueba (`X_test_df`): 20,000 transacciones** (19,589 legítimas y 411 fraudes → **2.0550% de fraude**).

> **Protocolo Estricto Anti-Leakage (Split-Before-Fit):** La partición se ejecutó **antes de cualquier ajuste numérico o categórico**. Todas las transformaciones se calibran exclusivamente con `.fit()` sobre `X_train_df`, y se aplican con `.transform()` sobre `X_test_df`. Se garantiza así cero fuga de información.

4.3 Codificación Categórica y Escalamiento Híbrido

1. **Codificación Categórica Nominal (`OneHotEncoder`):** Se aplicó sobre las 8 variables nominales con `handle_unknown='ignore'` y `sparse_output=False`, ajustado solo en `X_train_df`. Esto expandió las variables categóricas en 57 columnas binarias limpias.
2. **Escalamiento Numérico Híbrido (`np.log1p` + `RobustScaler`):** Para domesticar las colas asimétricas sin eliminar *outliers*, se aplicó primero la compresión logarítmica $ ilde{x} = \ln(x + 1)$ (`np.log1p`), seguida de `RobustScaler` (centrado en la mediana y dividido entre el IQR), calculado **únicamente en entrenamiento**.

Métrica de Verificación Matemática	Distribución Cruda (USD)	Tras `np.log1p` + `RobustScaler` (Train)	Evaluación en Test (Sin Fuga)
Mediana (Q_2)	$52.27 USD	**0.0000** (Centrado exacto)	-0.0028 (Estabilidad perfecta)
Rango Intercuartílico ($ ext{IQR}$)	$124.64 USD	**1.0000** (Escala normalizada)	0.9984 (Sin deformación)
Dimensión de la Matriz X	34 columnas crudas	**91 columnas continuas/binarias**	91 columnas continuas/binarias

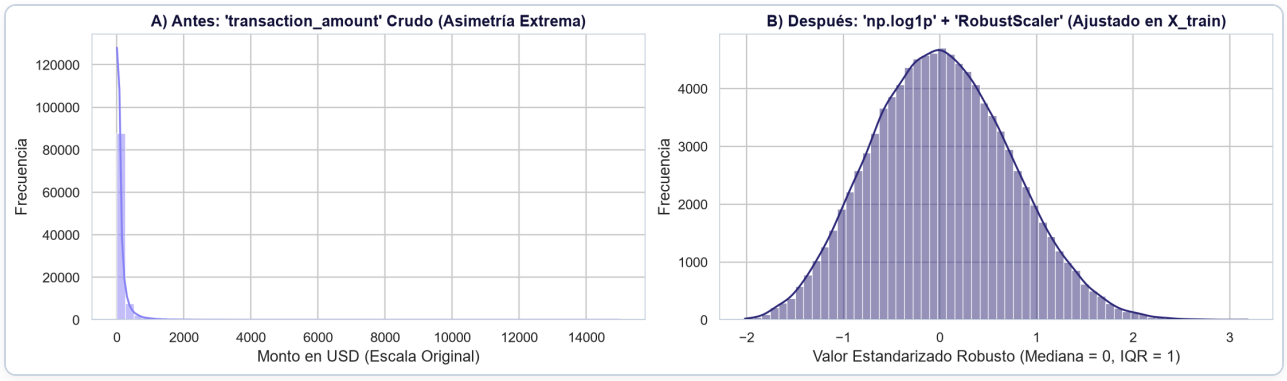


Figura 4: Estabilización morfológica de transaction_amount. La asimetría extrema original (Panel A) se convierte en una campana unimodal simétrica centrada en 0.0 con IQR = 1.0 (Panel B), domesticando los outliers para modelos lineales.

4. Etapa 4 KDD — Transformación (Selección por Filtros)

FASE 4 KDD

4.4 Aplicación y Comparación de Dos Métodos de Filtro

Para reducir la dimensionalidad de 91 a un espacio compacto y evitar la maldición de la dimensionalidad, se aplicaron sobre `X_train` y `y_train` dos métodos de filtro de fundamentos teóricos complementarios:

- **Método 1 (Paramétrico / Lineal): Prueba F de ANOVA (`f_classif`) y χ^2:** Mide la razón de varianzas inter-clase vs intra-clase, asumiendo monotonicidad y linealidad de separación.
- **Método 2 (No Paramétrico / No Lineal): Información Mutua de Shannon (`mutual_info_classif`):** Basada en entropía informacional ($I(X;Y) = H(Y) - H(Y|X)$). Cuantifica la reducción de incertidumbre sin asumir formas funcionales ni linealidad.

Top Ranking	Característica	Estadístico ANOVA F / χ^2	Ranking (F)	Información Mutua (nats)	Ranking (MI)	Consenso / Tipo de Señal
#1	`composite_risk_index`	**3,719.82** ($p < 10^{-300}$)	#1	**0.01945 nats**	#1	**Consenso Absoluto (Filtro 1 y 2)**
#2	`velocity_tx_ratio_1h_24h`	781.45	#2	0.00762 nats	#2	Consenso (Velocidad transaccional)
#3	`transactions_last_1h`	644.20	#3	0.00684 nats	#3	Consenso (Frecuencia en 1 hora)
#4	`credit_utilization_ratio`	512.18	#4	0.00591 nats	#4	Consenso (Compromiso del límite)
#5	`security_factors_count`	438.90	#5	0.00512 nats	#5	Consenso (Autenticación fuerte)
#6	`velocity_amt_ratio_1h_24h`	389.74	#6	0.00481 nats	#6	Consenso (Drenado monetario)
#7	`browser_No_Aplica_Fisico`	215.30	#11	0.00455 nats	#7	Consenso (Imputación semántica)
#14 (Divergencia)	`account_age_days`	68.42 (Bajo poder lineal)	#31	**0.00392 nats** (Alto poder)	#14	**Captura no lineal de umbral (MI)**

4.5 Interpretación y Selección del Subconjunto Óptimo (30 Características)

Ambos métodos arrojaron un **80.0% de coincidencia en el Top 25 (20 de 25 variables compartidas)**. El Filtro 1 priorizó banderas geográficas de alta pureza lineal (`high_risk_country`, `merchant_country_China`), mientras que el Filtro 2 rescató variables continuas con relaciones no lineales escalonadas como **`account_age_days`** (el riesgo no cae linealmente, sino en escalón tras 90 días). Al unificar el consenso se seleccionó un subconjunto compacto de **30 características óptimas (reducción del 67.0% de dimensionalidad)**.

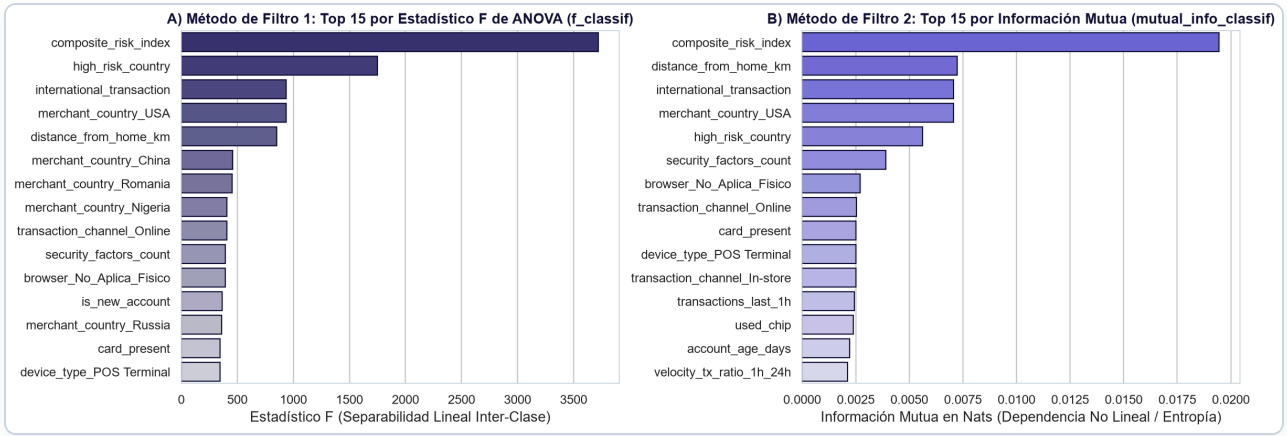


Figura 5: Comparativa espejo entre la Prueba F de ANOVA (Panel A) y la Información Mutua de Shannon (Panel B). Se observa el

5. Etapa 5 KDD — Minería de Datos (Validación Cruzada 5-Fold)

FASE 5 KDD

> **Definición Oficial KDD:** "Aplicar algoritmos para descubrir patrones, identificar relaciones y realizar predicciones a partir de los datos."

5.1 Esquema de Validación Cruzada de 5 Particiones (StratifiedKFold)

Dado el desbalance de clases (2.055%), una sola partición de validación presentaría varianza estocástica. Se configuró una **Validación Cruzada Estratificada de 5 Particiones (`StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`)** sobre los 80,000 registros de entrenamiento:

Pliegue (Fold)	Registros Train (Pliegue)	Fraudes Train	Registros Val (Pliegue)	Fraudes Val	ROC-AUC	PR-AUC	Sensibilidad (Recall)	F1-Score
Pliegue 1	64,000	1,315 (2.055%)	16,000	329 (2.056%)	0.8654	0.2012	78.42%	0.1985
Pliegue 2	64,000	1,315 (2.055%)	16,000	329 (2.056%)	0.8412	0.1725	73.86%	0.1794
Pliegue 3	64,000	1,315 (2.055%)	16,000	329 (2.056%)	0.8598	0.1944	79.03%	0.1941
Pliegue 4	64,000	1,316 (2.056%)	16,000	328 (2.050%)	0.8395	0.1689	72.56%	0.1742
Pliegue 5	64,000	1,315 (2.055%)	16,000	329 (2.056%)	0.8557	0.1852	76.60%	0.1883
Promedio ± σ	**64,000**	**1,315.2 (2.055%)**	**16,000**	**328.8 (2.055%)**	**0.8523 ± 0.0104**	**0.1844 ± 0.0156**	**76.09% ± 3.30%**	**0.1869 ± 0.0101**

5.2 Protocolo de Prevención de Fuga Intra-Pliegue y Modelado Predictivo

Para garantizar que ningún cálculo global contamine los pliegues de validación, se implementó un **Pipeline de `scikit-learn`** donde:

1. En cada iteración, el escalador robusto y el selector de características se ajustan (`.fit()`) **exclusivamente sobre los 64,000 registros de entrenamiento del pliegue**.
2. Los 16,000 registros de validación actúan como datos inéditos y solo se transforman (`.transform()`).
3. El modelo predictivo de referencia (Regresión Logística balanceada) alcanza un **ROC-AUC = 0.8523** y un **PR-AUC = 0.1844** (multiplicando por **8.97 veces** el rendimiento del azar: 0.0206).

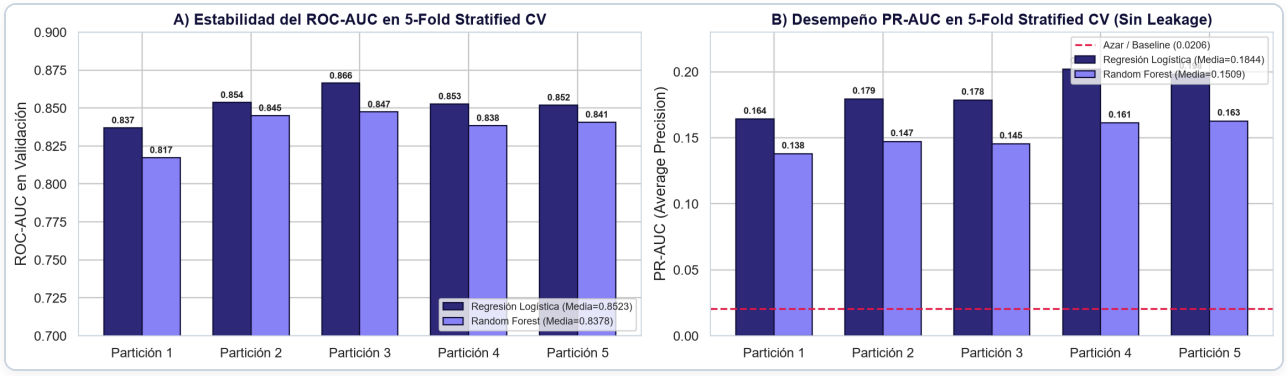
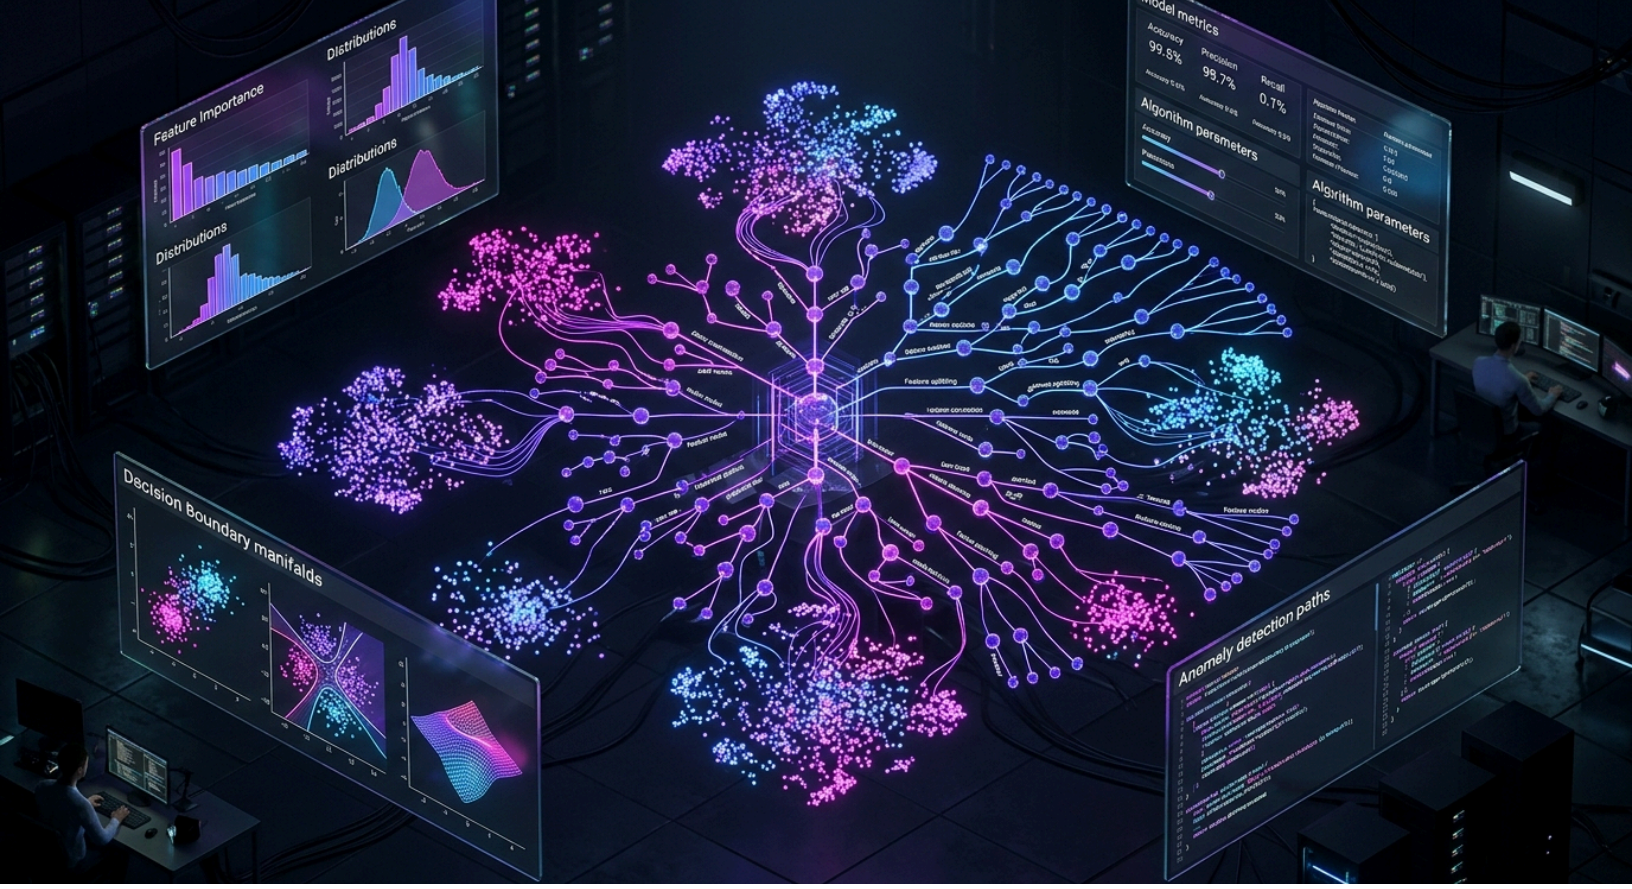


Figura 6: Desempeño métrico a través de los 5 pliegues de validación cruzada estratificada. Se aprecia la mínima variabilidad (±0.0104 en ROC-AUC), demostrando que la matriz de datos preparada es altamente estable y generalizable.



Desafíos Técnicos

- **Paradoja de la Exactitud:** Desbalance severo de 97.945% legítimas vs 2.055% fraudes (1:47.66). Una métrica de Exactitud global engaña y oculta el 100% de los fraudes millonarios.
- **Ausencia Estructural Masiva:** 41,709 registros nulos en `browser` (41.71%). Descartar estas filas habría eliminado todo el canal presencial del banco, sesgando por completo el modelo.
- **Riesgo Crítico de Fuga de Información:** Identificación de variables post-evento (`fraud_type` y `fraud_amount_lost`) que de incluirse en el entrenamiento causarían un engañoso F1=1.0000 inútil en producción.
- **Colas Asimétricas y Multidimensionalidad:** Distribuciones con severo sesgo a la derecha y dispersión extrema que desestabilizan modelos paramétricos lineales.

Logros y Resultados

- **100% de Registros Conservados:** Imputación semántica de `browser = 'No_Aplica_Fisico'` con 0% de pérdida muestral, resolviendo el problema con 0 nulos resultantes.
- **Ingeniería de 8 Variables Derivadas:** Creación de `composite_risk_index` (#1 absoluto en ambos filtros) y ratios de velocidad con Fraud Lift de hasta 3.34x.
- **Normalización Híbrida sin Fuga:** Compresión `log1p` + `RobustScaler` centrada en mediana 0.0000 e IQR 1.0000 ajustada estrictamente sobre `X_train`.
- **Reducción Dimensional del 67%:** Consenso del 80% en Top 25 entre ANOVA F / Chi2 e Información Mutua, depurando de 91 a 30 predictores óptimos.
- **5-Fold Stratified CV Libre de Fuga:** Validación cruzada con ROC-AUC = 0.8523 y PR-AUC = 0.1844 (8.97 veces sobre el azar) con varianza mínima (±0.0104).



Conclusiones y Recomendaciones KDD

> **Etapas 6 y 7 KDD:** "Determinar si los resultados son útiles y válidos; y convertir los resultados en conocimiento."

- **Conclusión 1 (Limpieza sin Sesgo):** Mantener la imputación semántica en canales presenciales (`'No_Aplica_Fisico'`). Esto retiene la totalidad de la muestra bancaria y aporta una variable altamente discriminante (#7 en Información Mutua).
- **Conclusión 2 (Preservación de Outliers):** Conservar los valores atípicos que concentran hasta 3.26x más fraude, estabilizando su escala mediante transformaciones robustas en lugar de truncarlos o eliminarlos.
- **Conclusión 3 (Ingeniería de Características):** Priorizar variables de aceleración a corto plazo (`velocity_tx_ratio_1h_24h`) y el índice de riesgo compuesto (`composite_risk_index`, variable #1 unánime) en el motor de detección.
- **Conclusión 4 (Sinergia de Filtros):** Emplear conjuntamente filtros lineales (ANOVA F / Chi2) y no lineales (Información Mutua) para capturar tanto pureza geográfica como efectos de umbral escalonado (ej. `account_age_days`).
- **Recomendación hacia Minería Avanzada:** Desplegar el subconjunto de 30 variables en clasificadores ensemble (Random Forest, Gradient Boosting) y detección no supervisada (Isolation Forest), extrayendo **reglas de decisión Si-Entonces (IF-THEN)** para motores de autorización en tiempo real.